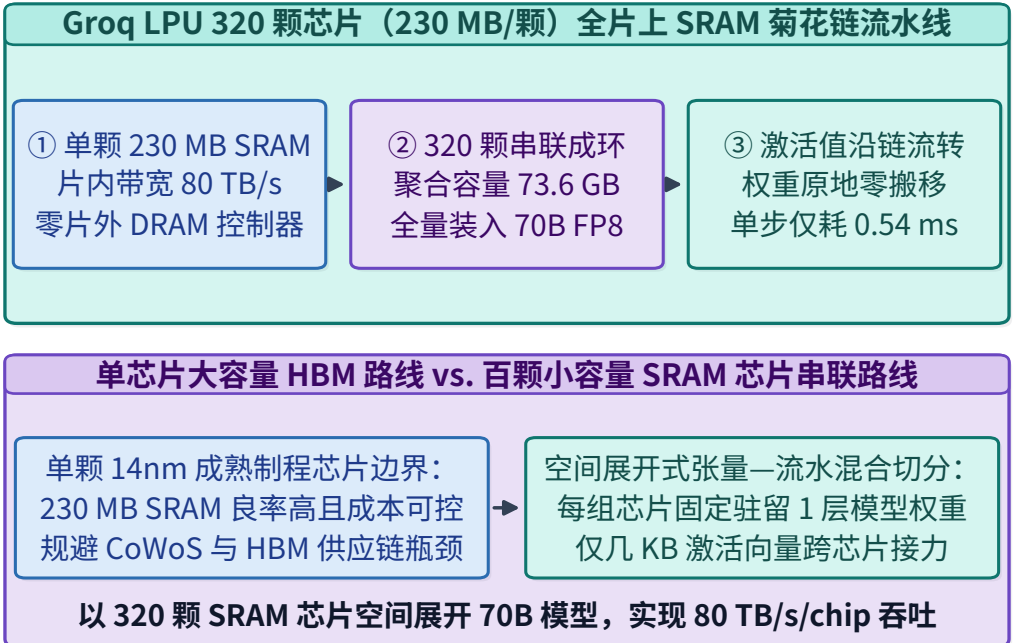
Groq LPU 320 颗芯片（230 MB/颗）全片上 SRAM 菊花链流水线
① 单颗 230 MB SRAM
片内带宽 80 TB/s
零片外 DRAM 控制器
② 320 颗串联成环
聚合容量 73.6 GB
全量装入 70B FP8
③ 激活值沿链流转
权重原地零搬移
单步仅耗 0.54 ms
单芯片大容量 HBM 路线 vs. 百颗小容量 SRAM 芯片串联路线
单颗 14nm 成熟制程芯片边界：
230 MB SRAM 良率高且成本可控
规避 CoWoS 与 HBM 供应链瓶颈
空间展开式张量—流水混合切分：
每组芯片固定驻留 1 层模型权重
仅几 KB 激活向量跨芯片接力
以 320 颗 SRAM 芯片空间展开 70B 模型，实现 80 TB/s/chip 吞吐