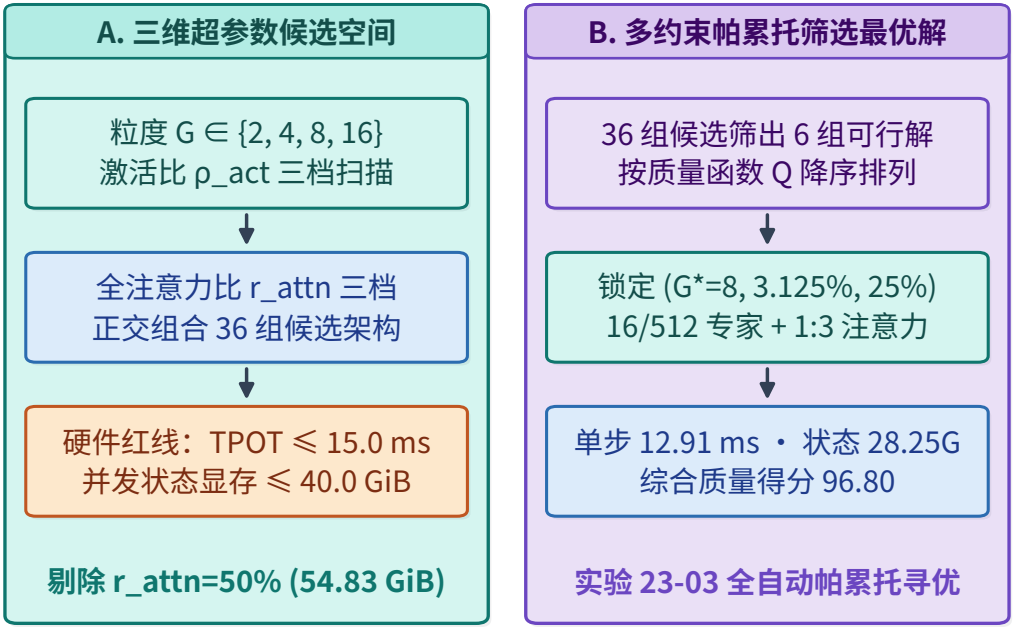
A. 三维超参数候选空间
粒度 G ∈ {2, 4, 8, 16}
激活比 ρ_act 三档扫描
全注意力比 r_attn 三档
正交组合 36 组候选架构
硬件红线：TPOT ⩽ 15.0 ms
并发状态显存 ⩽ 40.0 GiB
剔除 r_attn=50% (54.83 GiB)
B. 多约束帕累托筛选最优解
36 组候选筛出 6 组可行解
按质量函数 Q 降序排列
锁定 (G*=8, 3.125%, 25%)
16/512 专家 + 1:3 注意力
单步 12.91 ms · 状态 28.25G
综合质量得分 96.80
实验 23-03 全自动帕累托寻优