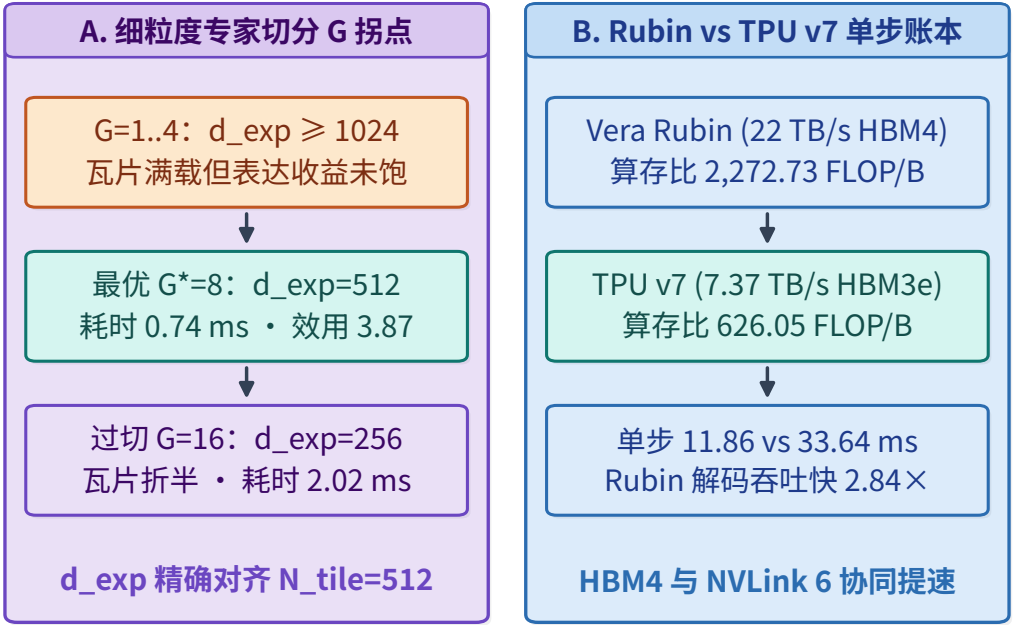
A. 细粒度专家切分 G 拐点
G=1..4：d_exp ⩾ 1024
瓦片满载但表达收益未饱
最优 G*=8：d_exp=512
耗时 0.74 ms · 效用 3.87
过切 G=16：d_exp=256
瓦片折半 · 耗时 2.02 ms
d_exp 精确对齐 N_tile=512
B. Rubin vs TPU v7 单步账本
Vera Rubin (22 TB/s HBM4)
算存比 2,272.73 FLOP/B
TPU v7 (7.37 TB/s HBM3e)
算存比 626.05 FLOP/B
单步 11.86 vs 33.64 ms
Rubin 解码吞吐快 2.84×
HBM4 与 NVLink 6 协同提速