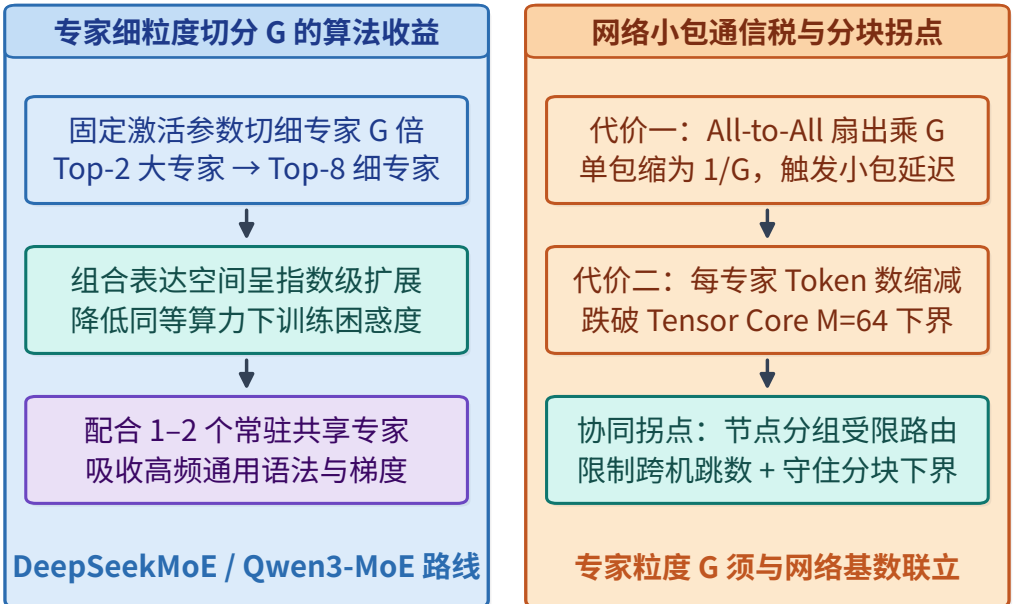
专家细粒度切分 G 的算法收益
固定激活参数切细专家 G 倍
Top-2 大专家 → Top-8 细专家
组合表达空间呈指数级扩展
降低同等算力下训练困惑度
配合 1–2 个常驻共享专家
吸收高频通用语法与梯度
DeepSeekMoE / Qwen3-MoE 路线
网络小包通信税与分块拐点
代价一：All-to-All 扇出乘 G
单包缩为 1/G，触发小包延迟
代价二：每专家 Token 数缩减
跌破 Tensor Core M=64 下界
协同拐点：节点分组受限路由
限制跨机跳数 + 守住分块下界
专家粒度 G 须与网络基数联立