Nemotron-CC 多分类器集成打分与合成改写抢救（Rephrasing）

多分类器互补集成
教育打分+指令打分
划分 20 个质量桶

→

高质桶受控上采样
Top-5% 精品训 3 轮
低质桶尽早丢弃

→

高价值残缺页抢救
含稀缺知识但排版碎
送入大模型合成改写

突破“激进过滤导致知识枯竭”的合成改写闭环

为什么不能盲目丢弃中低分网页：
许多排障贴格式杂乱但含稀缺经验
直接过滤会损失长尾专业知识

→

百科风格合成改写（Rephrase）：
将破碎问答重写为结构化教材段落
使有效精品词元总量扩充 1.8 倍

分类器集成实现精细分层，合成改写将粗糙矿石冶炼成精品语料