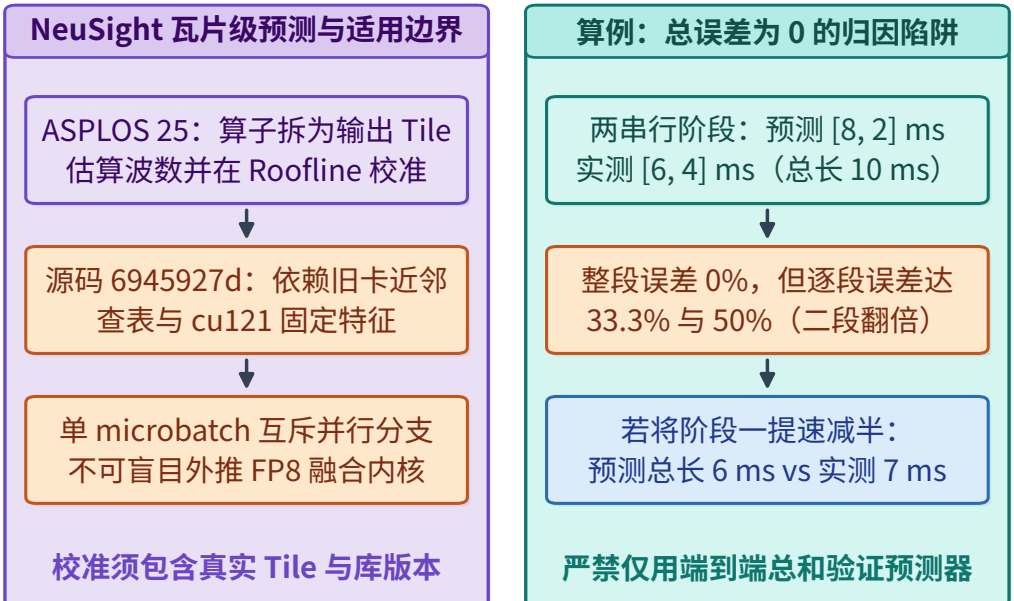
NeuSight 瓦片级预测与适用边界
ASPLOS 25：算子拆为输出 Tile 估算波数并在 Roofline 校准
源码 6945927d：依赖旧卡近邻查表与 cu121 固定特征
单 microbatch 互斥并行分支不可盲目外推 FP8 融合内核
校准须包含真实 Tile 与库版本
算例：总误差为 0 的归因陷阱
两串行阶段：预测 [8, 2] ms 实测 [6, 4] ms（总长 10 ms）
整段误差 0%，但逐段误差达 33.3% 与 50%（二段翻倍）
若将阶段一提速减半：预测总长 6 ms vs 实测 7 ms
严禁仅用端到端总和验证预测器