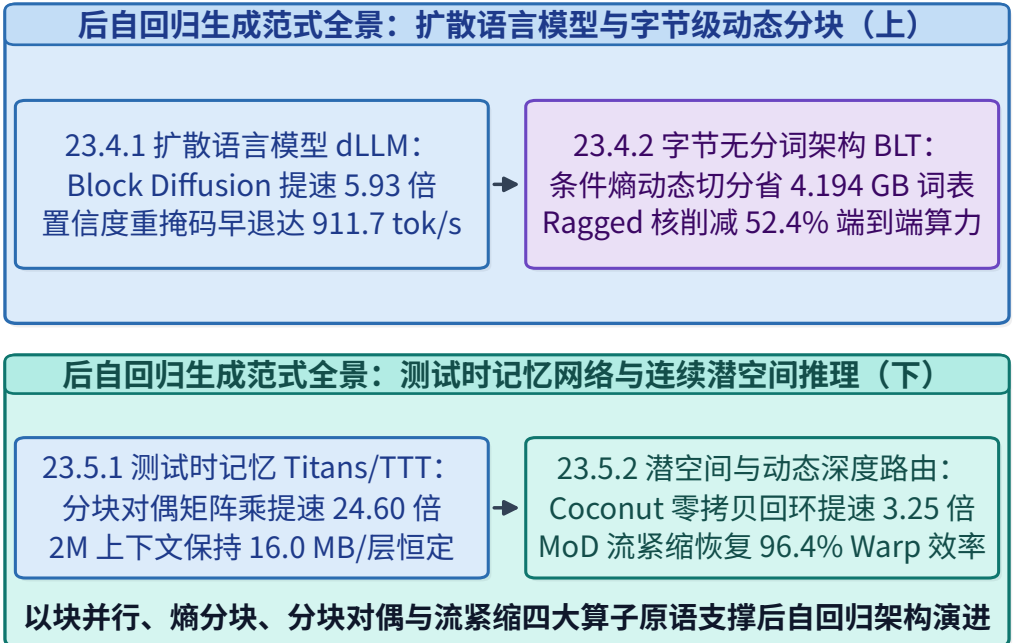
后自回归生成范式全景：扩散语言模型与字节级动态分块（上）
23.4.1 扩散语言模型 dLLM：
Block Diffusion 提速 5.93 倍
置信度重掩码早退达 911.7 tok/s
23.4.2 字节无分词架构 BLT：
条件熵动态切分省 4.194 GB 词表
Ragged 核削减 52.4% 端到端算力
后自回归生成范式全景：测试时记忆网络与连续潜空间推理（下）
23.5.1 测试时记忆 Titans/TTT：
分块对偶矩阵乘提速 24.60 倍
2M 上下文保持 16.0 MB/层恒定
23.5.2 潜空间与动态深度路由：
Coconut 零拷贝回环提速 3.25 倍
MoD 流紧缩恢复 96.4% Warp 效率
以块并行、熵分块、分块对偶与流紧缩四大算子原语支撑后自回归架构演进