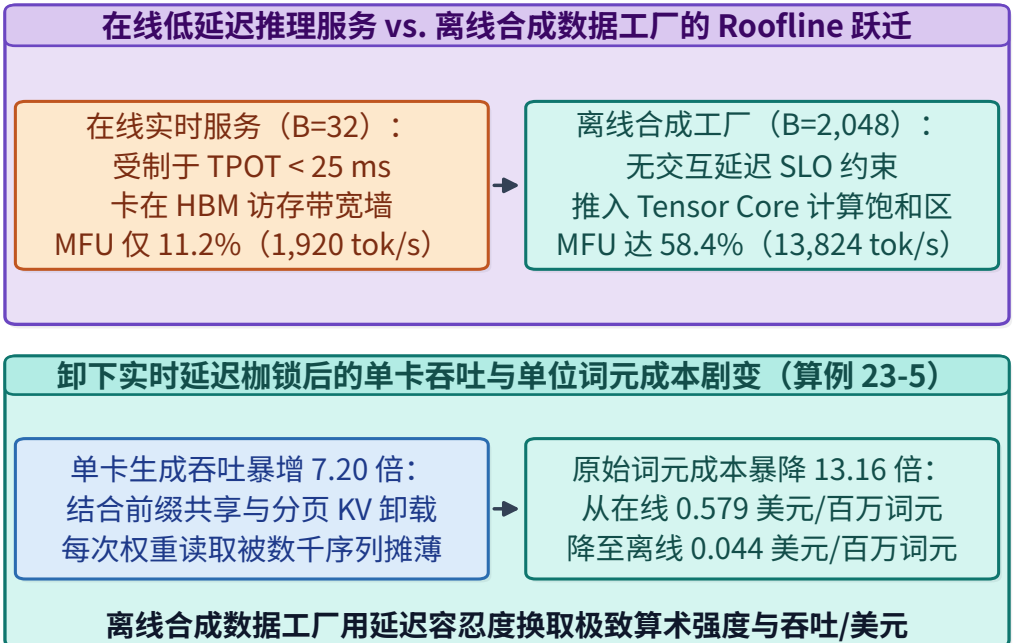
在线低延迟推理服务 vs. 离线合成数据工厂的 Roofline 跃迁
在线实时服务（B=32）：
受制于 TPOT < 25 ms
卡在 HBM 访存带宽墙
MFU 仅 11.2%（1,920 tok/s）
离线合成工厂（B=2,048）：
无交互延迟 SLO 约束
推入 Tensor Core 计算饱和区
MFU 达 58.4%（13,824 tok/s）
卸下实时延迟枷锁后的单卡吞吐与单位词元成本剧变（算例 23-5）
单卡生成吞吐暴增 7.20 倍：
结合前缀共享与分页 KV 卸载
每次权重读取被数千序列摊薄
原始词元成本暴降 13.16 倍：
从在线 0.579 美元/百万词元
降至离线 0.044 美元/百万词元
离线合成数据工厂用延迟容忍度换取极致算术强度与吞吐/美元