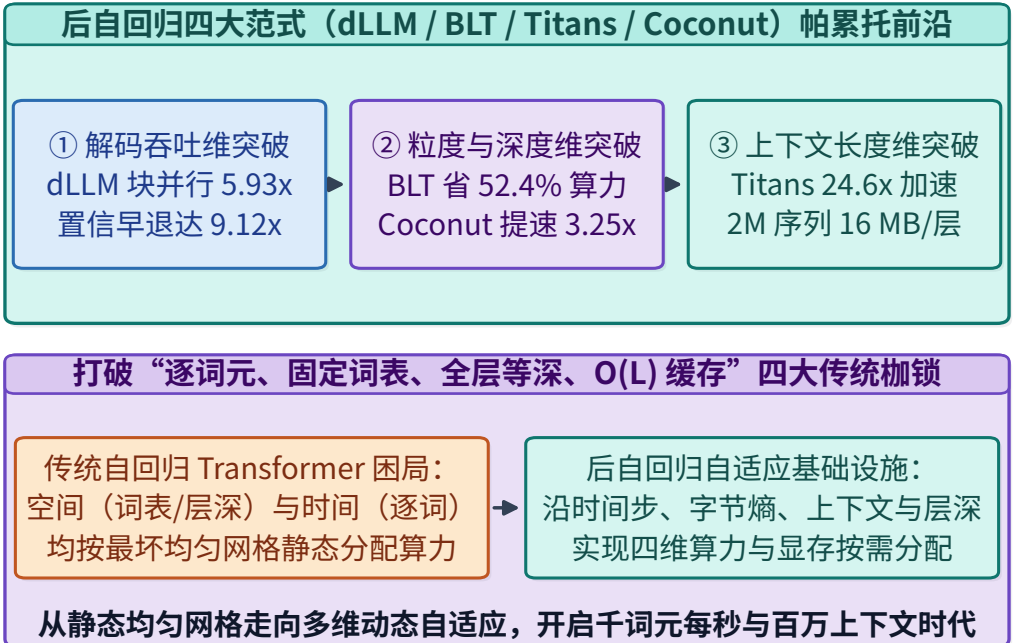
后自回归四大范式（dLLM / BLT / Titans / Coconut）帕累托前沿
① 解码吞吐维突破
dLLM 块并行 5.93x
置信早退达 9.12x
② 粒度与深度维突破
BLT 省 52.4% 算力
Coconut 提速 3.25x
③ 上下文长度维突破
Titans 24.6x 加速
2M 序列 16 MB/层
打破“逐词元、固定词表、全层等深、O(L) 缓存”四大传统枷锁
传统自回归 Transformer 困局：
空间（词表/层深）与时间（逐词）
均按最坏均匀网格静态分配算力
后自回归自适应基础设施：
沿时间步、字节熵、上下文与层深
实现四维算力与显存按需分配
从静态均匀网格走向多维动态自适应，开启千词元每秒与百万上下文时代