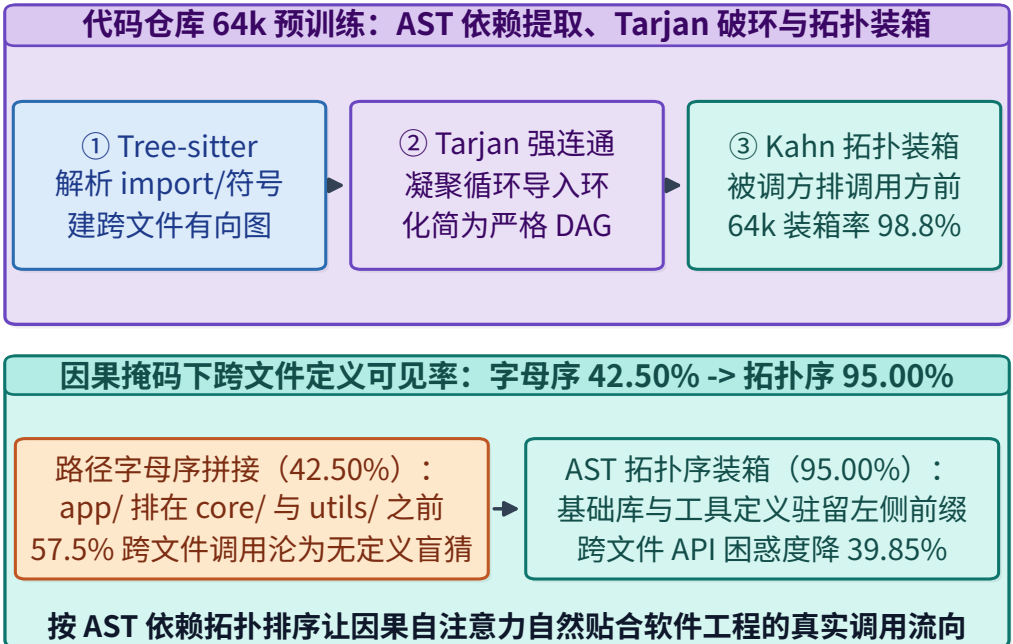
代码仓库 64k 预训练：AST 依赖提取、Tarjan 破环与拓扑装箱
① Tree-sitter
解析 import/符号
建跨文件有向图
② Tarjan 强连通
凝聚循环导入环
化简为严格 DAG
③ Kahn 拓扑装箱
被调方排调用方前
64k 装箱率 98.8%
因果掩码下跨文件定义可见率：字母序 42.50% -> 拓扑序 95.00%
路径字母序拼接（42.50%）：
app/ 排在 core/ 与 utils/ 之前
57.5% 跨文件调用沦为无定义盲猜
AST 拓扑序装箱（95.00%）：
基础库与工具定义驻留左侧前缀
跨文件 API 困惑度降 39.85%
按 AST 依赖拓扑排序让因果自注意力自然贴合软件工程的真实调用流向