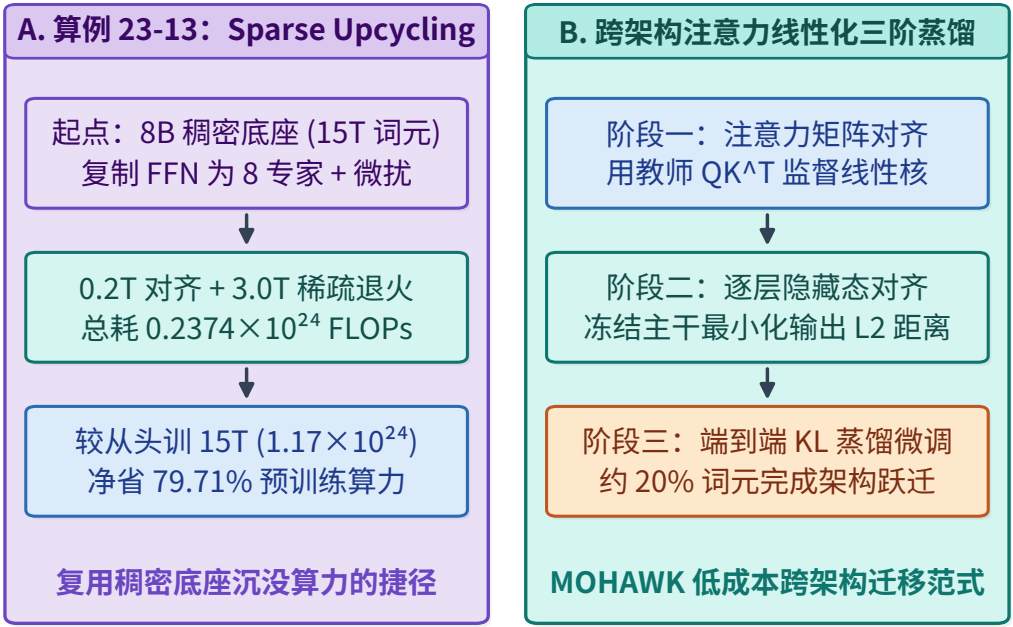
A. 算例 23-13：Sparse Upcycling
起点：8B 稠密底座 (15T 词元)
复制 FFN 为 8 专家 + 微扰
0.2T 对齐 + 3.0T 稀疏退火
总耗 0.2374×10^24 FLOPs
较从头训 15T (1.17×10^24)
净省 79.71% 预训练算力
复用稠密底座沉没算力的捷径
B. 跨架构注意力线性化三阶蒸馏
阶段一：注意力矩阵对齐
用教师 QK^T 监督线性核
阶段二：逐层隐藏态对齐
冻结主干最小化输出 L2 距离
阶段三：端到端 KL 蒸馏微调
约 20% 词元完成架构跃迁
MOHAWK 低成本跨架构迁移范式