片上 SRAM 阵列与 HBM GPU 的并发度—成本交叉点（B*=14.2）

① 低并发 B <= 14
SRAM 快 11.23 倍
主导实时 Agent 交互

② 盈亏平衡点 B*
B_cross = 14.2
单位词元成本相等

③ 高并发 B = 128
HBM 吞吐 6,400/s
成本优势达 6.8 倍

为什么云厂商需要“低并发 SRAM 加速池 + 高并发 HBM 批处理池”？

SRAM 架构的容量资本开支制约：
70 GB SRAM 需百颗芯片分摊
扩大 Batch 无法进一步提速

HBM 架构的高并发算力复用：
4 张 H100 在 B=128 下算力满载
单词元摊销硬件成本降低 6.8 倍

定量确立 B*=14.2 交叉律：交互式串行推理用 SRAM，高吞吐批处理用 HBM