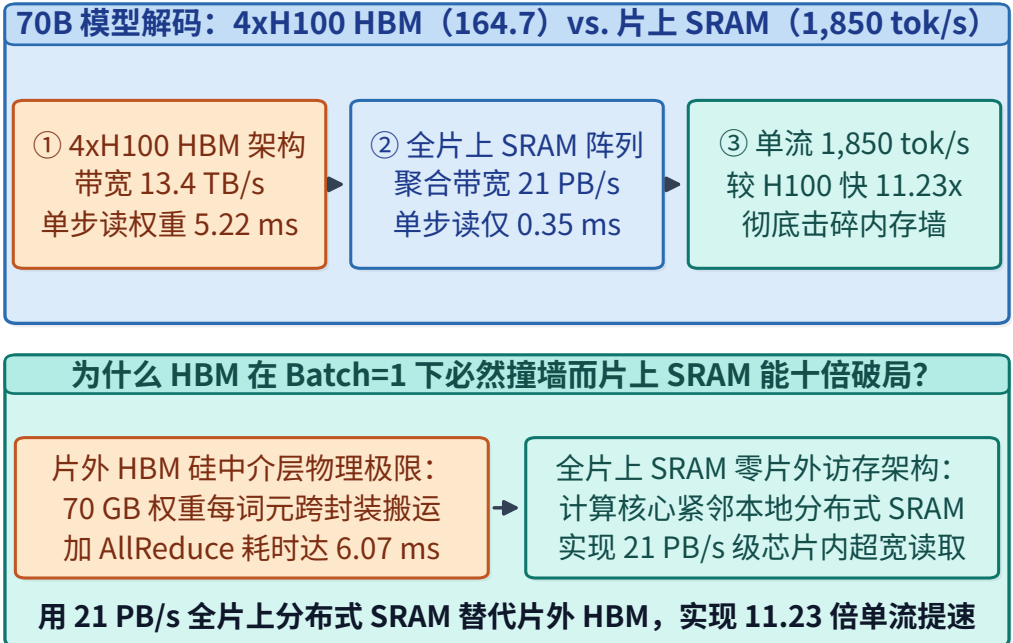
70B 模型解码：4xH100 HBM（164.7）vs. 片上 SRAM（1,850 tok/s）
① 4xH100 HBM 架构
带宽 13.4 TB/s
单步读权重 5.22 ms
② 全片上 SRAM 阵列
聚合带宽 21 PB/s
单步读仅 0.35 ms
③ 单流 1,850 tok/s
较 H100 快 11.23x
彻底击碎内存墙
为什么 HBM 在 Batch=1 下必然撞墙而片上 SRAM 能十倍破局？
片外 HBM 硅中介层物理极限：
70 GB 权重每词元跨封装搬运
加 AllReduce 耗时达 6.07 ms
全片上 SRAM 零片外访存架构：
计算核心紧邻本地分布式 SRAM
实现 21 PB/s 级芯片内超宽读取
用 21 PB/s 全片上分布式 SRAM 替代片外 HBM，实现 11.23 倍单流提速