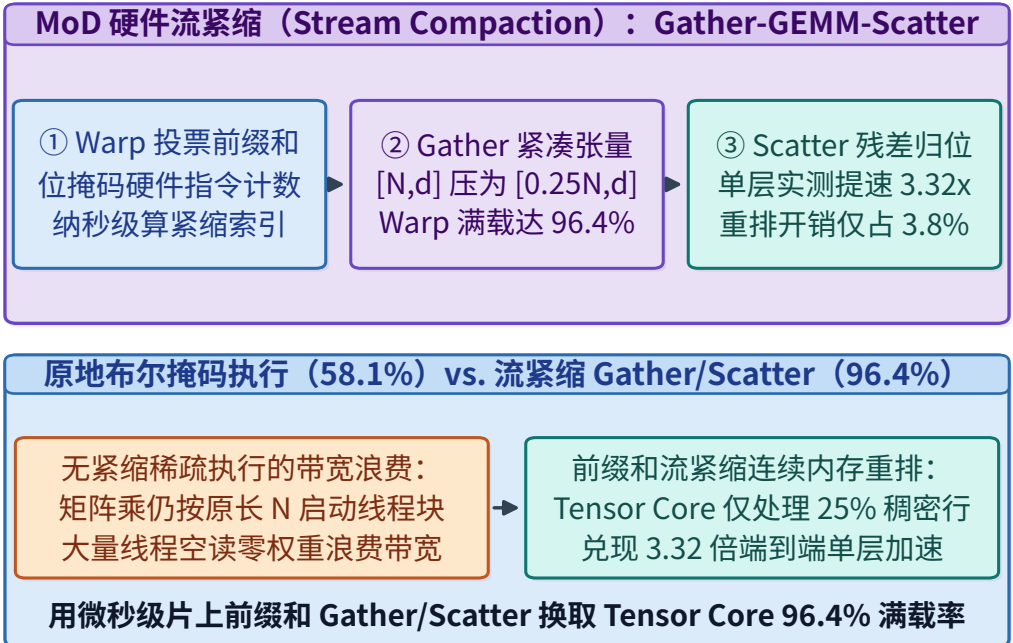
MoD 硬件流紧缩（Stream Compaction）：Gather-GEMM-Scatter
① Warp 投票前缀和
位掩码硬件指令计数
纳秒级算紧缩索引
② Gather 紧凑张量
[N,d] 压为 [0.25N,d]
Warp 满载达 96.4%
③ Scatter 残差归位
单层实测提速 3.32x
重排开销仅占 3.8%
原地布尔掩码执行（58.1%）vs. 流紧缩 Gather/Scatter（96.4%）
无紧缩稀疏执行的带宽浪费：
矩阵乘仍按原长 N 启动线程块
大量线程空读零权重浪费带宽
前缀和流紧缩连续内存重排：
Tensor Core 仅处理 25% 稠密行
兑现 3.32 倍端到端单层加速
用微秒级片上前缀和 Gather/Scatter 换取 Tensor Core 96.4% 满载率