TTT 快速权重更新：逐词元串行（1.5）vs. 分块对偶（48 FLOP/B）

① 逐词元串行更新
每步读写 128x128
吞吐仅 42k tok/s

② 分块对偶 b=64
聚合成矩阵乘 MMA
强度升至 48 FLOP/B

③ 吞吐 1,033k tok/s
算子提速 24.60 倍
吃满 Tensor Core

如何将测试时串行梯度下降转化为 Tensor Core 分块矩阵乘？

逐词元在线 SGD 的硬件困局：
64 步产生 64 次寄存器写回依赖
无法调用矩阵乘单元陷入算力饥饿

Chunk-wise Dual Form 对偶化：
块内梯度聚合为 [128,64]x[64,128]
单次片上归约跑出 24.6 倍加速

利用块内线性可加性将逐词元外积折叠为分块 GEMM，打通测试时训练算力