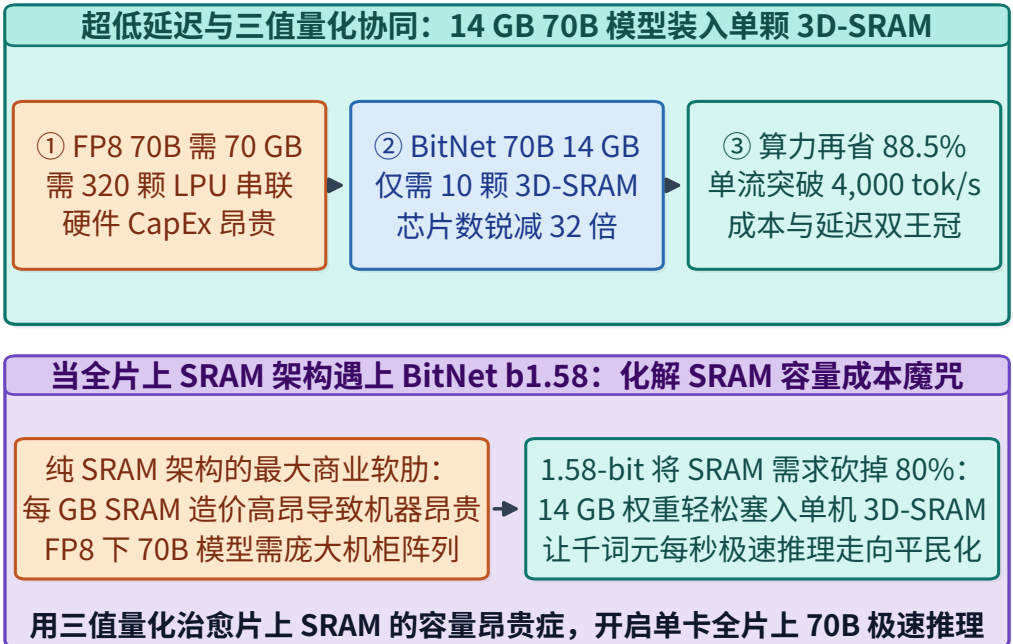
超低延迟与三值量化协同：14 GB 70B 模型装入单颗 3D-SRAM
① FP8 70B 需 70 GB
需 320 颗 LPU 串联
硬件 CapEx 昂贵
② BitNet 70B 14 GB
仅需 10 颗 3D-SRAM
芯片数锐减 32 倍
③ 算力再省 88.5%
单流突破 4,000 tok/s
成本与延迟双王冠
当全片上 SRAM 架构遇上 BitNet b1.58：化解 SRAM 容量成本魔咒
纯 SRAM 架构的最大商业软肋：
每 GB SRAM 造价高昂导致机器昂贵
FP8 下 70B 模型需庞大机柜阵列
1.58-bit 将 SRAM 需求砍掉 80%：
14 GB 权重轻松塞入单机 3D-SRAM
让千词元每秒极速推理走向平民化
用三值量化治愈片上 SRAM 的容量昂贵症，开启单卡全片上 70B 极速推理