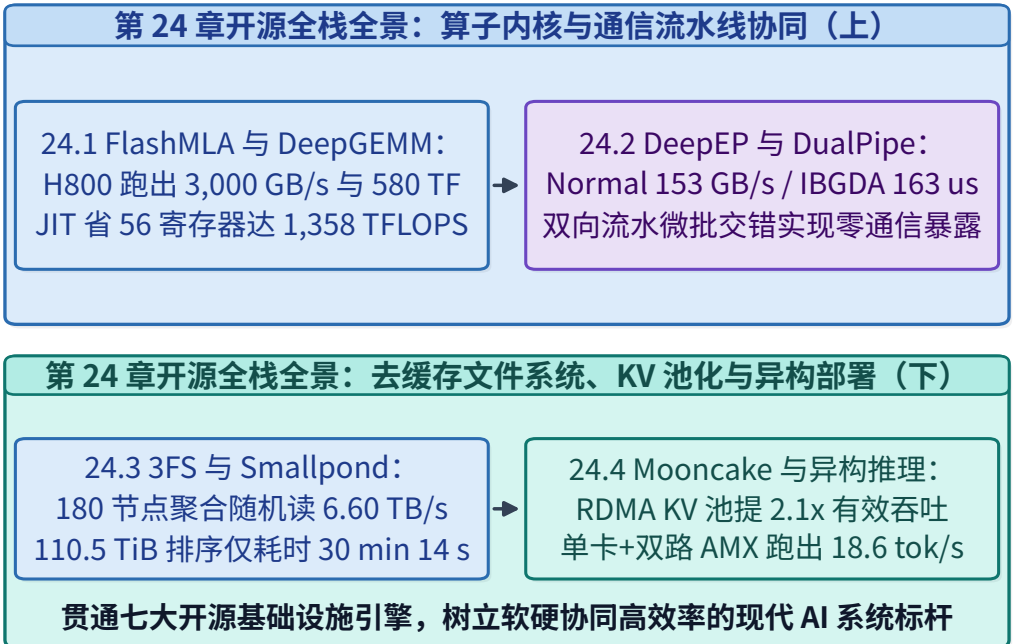
第 24 章开源全栈全景：算子内核与通信流水线协同（上）
24.1 FlashMLA 与 DeepGEMM：
H800 跑出 3,000 GB/s 与 580 TF
JIT 省 56 寄存器达 1,358 TFLOPS
24.2 DeepEP 与 DualPipe：
Normal 153 GB/s / IBGDA 163 us
双向流水微批交错实现零通信暴露
第 24 章开源全栈全景：去缓存文件系统、KV 池化与异构部署（下）
24.3 3FS 与 Smallpond：
180 节点聚合随机读 6.60 TB/s
110.5 TiB 排序仅耗时 30 min 14 s
24.4 Mooncake 与异构推理：
RDMA KV 池提 2.1x 有效吞吐
单卡+双路 AMX 跑出 18.6 tok/s
贯通七大开源基础设施引擎，树立软硬协同高效率的现代 AI 系统标杆