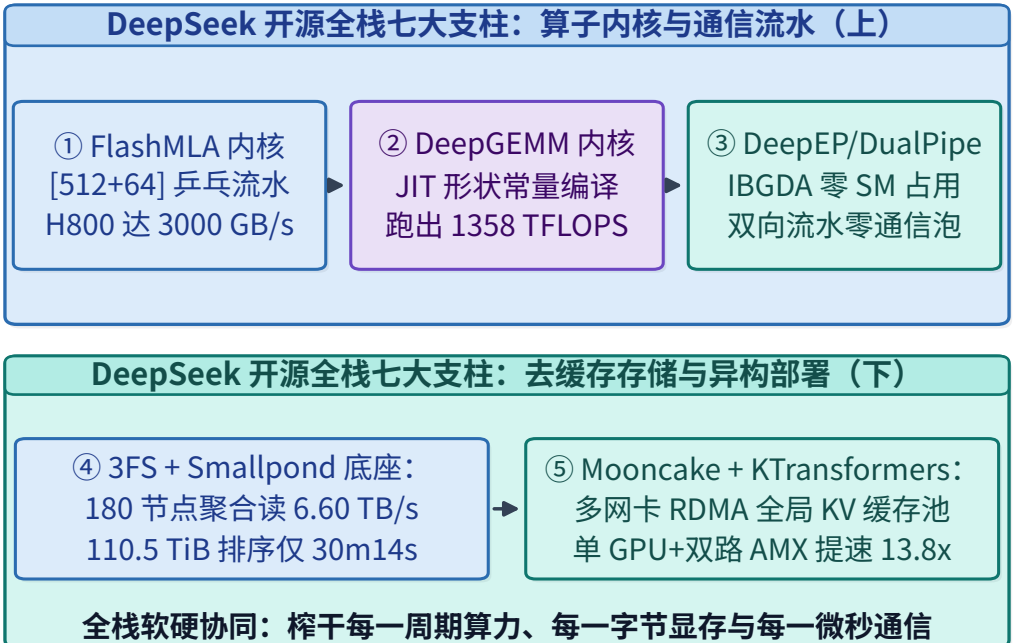
DeepSeek 开源全栈七大支柱：算子内核与通信流水（上）
① FlashMLA 内核
[512+64] 乒乓流水
H800 达 3000 GB/s
② DeepGEMM 内核
JIT 形状常量编译
跑出 1358 TFLOPS
③ DeepEP/DualPipe
IBGDA 零 SM 占用
双向流水零通信泡
DeepSeek 开源全栈七大支柱：去缓存存储与异构部署（下）
④ 3FS + Smallpond 底座：
180 节点聚合读 6.60 TB/s
110.5 TiB 排序仅 30m14s
⑤ Mooncake + KTransformers：
多网卡 RDMA 全局 KV 缓存池
单 GPU+双路 AMX 提速 13.8x
全栈软硬协同：榨干每一周期算力、每一字节显存与每一微秒通信