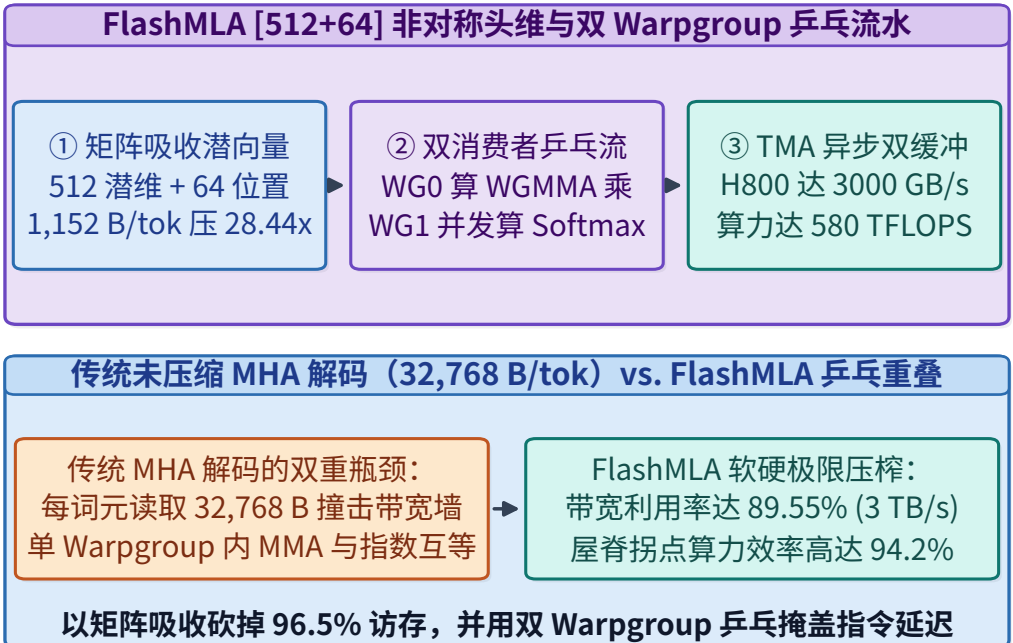
FlashMLA [512+64] 非对称头维与双 Warpgroup 乒乓流水
① 矩阵吸收潜向量
512 潜维 + 64 位置
1,152 B/tok 压 28.44x
② 双消费者乒乓流
WG0 算 WGMMA 乘
WG1 并发算 Softmax
③ TMA 异步双缓冲
H800 达 3000 GB/s
算力达 580 TFLOPS
传统未压缩 MHA 解码（32,768 B/tok）vs. FlashMLA 乒乓重叠
传统 MHA 解码的双重瓶颈：
每词元读取 32,768 B 撞击带宽墙
单 Warpgroup 内 MMA 与指数互等
FlashMLA 软硬极限压榨：
带宽利用率达 89.55% (3 TB/s)
屋脊拐点算力效率高达 94.2%
以矩阵吸收砍掉 96.5% 访存，并用双 Warpgroup 乒乓掩盖指令延迟