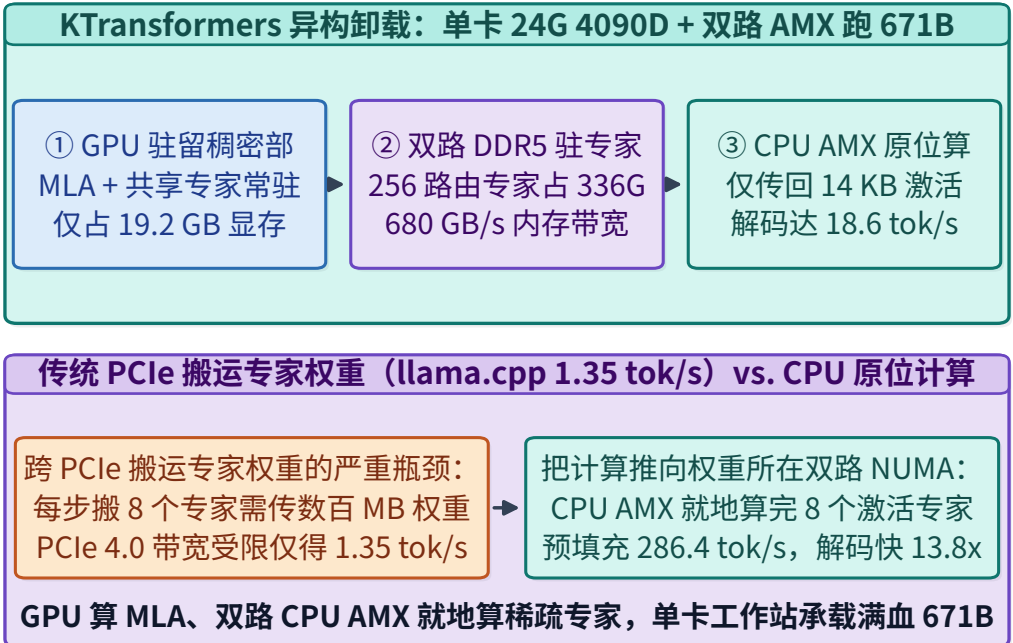
KTransformers 异构卸载：单卡 24G 4090D + 双路 AMX 跑 671B
① GPU 驻留稠密部 MLA + 共享专家常驻 仅占 19.2 GB 显存
② 双路 DDR5 驻专家 256 路由专家占 336G 680 GB/s 内存带宽
③ CPU AMX 原位算 仅传回 14 KB 激活 解码达 18.6 tok/s
传统 PCIe 搬运专家权重（llama.cpp 1.35 tok/s）vs. CPU 原位计算
跨 PCIe 搬运专家权重的严重瓶颈： 每步搬 8 个专家需传数百 MB 权重 PCIe 4.0 带宽受限仅得 1.35 tok/s
把计算推向权重所在双路 NUMA： CPU AMX 就地算完 8 个激活专家 预填充 286.4 tok/s，解码快 13.8x
GPU 算 MLA、双路 CPU AMX 就地算稀疏专家，单卡工作站承载满血 671B