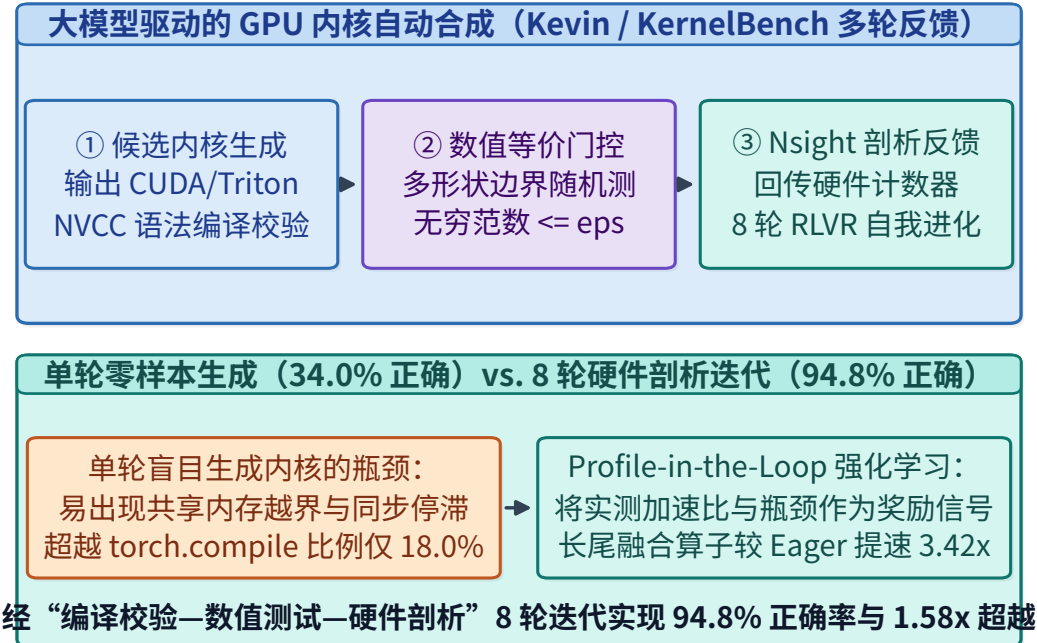
大模型驱动的 GPU 内核自动合成（Kevin / KernelBench 多轮反馈）
① 候选内核生成
输出 CUDA/Triton
NVCC 语法编译校验
② 数值等价门控
多形状边界随机测
无穷范数 <= eps
③ Nsight 剖析反馈
回传硬件计数器
8 轮 RLVR 自我进化
单轮零样本生成（34.0% 正确）vs. 8 轮硬件剖析迭代（94.8% 正确）
单轮盲目生成内核的瓶颈：
易出现共享内存越界与同步停滞
超越 torch.compile 比例仅 18.0%
Profile-in-the-Loop 强化学习：
将实测加速比与瓶颈作为奖励信号
长尾融合算子较 Eager 提速 3.42x
经“编译校验—数值测试—硬件剖析”8 轮迭代实现 94.8% 正确率与 1.58x 超越