Mooncake 基于负载预测的提前拒绝与 SLA Goodput 准入控制

① 实时排队时延预测
结合 KV 池余量建模
入队前精准算 TTFT

② 超 SLA 提前拒绝
不浪费一周期 GPU
避免级联超时雪崩

③ 有效吞吐翻倍涨
突发流量稳守 SLA
Goodput 提升 2.1x

传统盲目入队先到先服务（FCFS 雪崩）vs. 预测式准入控制对比

过载状态下的全员超时陷阱：
盲目接收请求导致排队超过 5 秒
算完返回时客户端早已断开作废

以 Goodput（合规吞吐）为纲：
果断拦截注定违约的尾部过载请求
保障场内运行任务严守延迟红线

在网关层预判 KV 容量与排队延迟，用提前拒绝换取过载下 2.1x 有效吞吐