Mooncake Transfer Engine：多网卡 RDMA 拓扑感知全局 KV 缓存池

① 聚合多级存储池
HBM + DRAM + SSD
全局前缀块哈希寻址

② 拓扑感知选网卡
自动匹配同 NUMA
聚合多口 RDMA 带宽

③ 零拷贝跨机搬运
Prefill 写 Decode 读
长文本 TTFT 降 68%

单机孤立 KV 缓存（重复重算）vs. Mooncake 数据中心级 KV 共享池

长文档与多轮的重复预填充：
请求漂移至新节点时被迫重算前缀
浪费预填充算力并拉高首字延迟

跨节点 RDMA 单边读写直通：
从远端主机内存拉取历史 KV 块
比重新跑 671B 模型前向快十倍

将全集群内存与 SSD 编织为统一 KV 缓存池，彻底解耦 Prefill 与 Decode