算子级动态电压频率调节（Per-Kernel DVFS）三次方能效方程

① 识别算子屋脊属性
GEMM 属算力受限
AllReduce 属访存受限

② 访存算子降频 18%
HBM 带宽完全不变
耗时仅增 0.72%

③ 三次方功耗下降
动态功耗降 26.5%
显著优化能效积

全程固定最高 Boost 频率（高功耗发热）vs. 算子感知精细调频

盲目固定最高核心频率的浪费：
跑集合通信或解码注意力时 SM 空等
高电压高频白白转化成废热

微秒级硬件 PLL 动态调频：
在访存与通信阶段顺势降频 18%
计算性能无损而功耗立降 26.5%

利用 P_dyn 正比于 V^2*f 物理定律，降频 18% 换取 26.5% 动态功耗节省