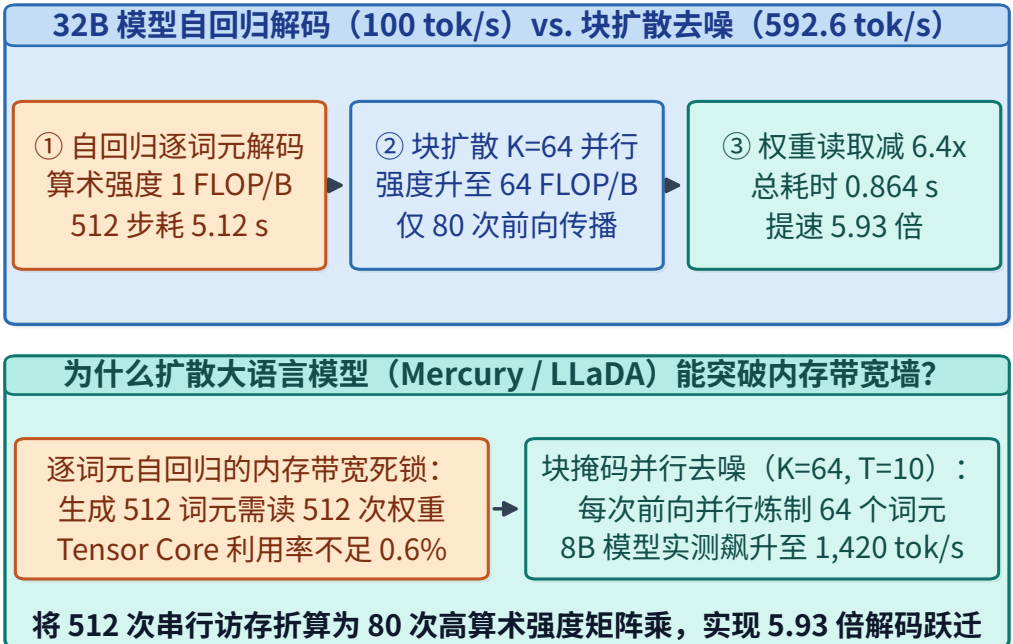
32B 模型自回归解码（100 tok/s）vs. 块扩散去噪（592.6 tok/s）
① 自回归逐词元解码
算术强度 1 FLOP/B
512 步耗 5.12 s
② 块扩散 K=64 并行
强度升至 64 FLOP/B
仅 80 次前向传播
③ 权重读取减 6.4x
总耗时 0.864 s
提速 5.93 倍
为什么扩散大语言模型（Mercury / LLaDA）能突破内存带宽墙?
逐词元自回归的内存带宽死锁：
生成 512 词元需读 512 次权重
Tensor Core 利用率不足 0.6%
块掩码并行去噪（K=64, T=10）：
每次前向并行炼制 64 个词元
8B 模型实测飙升至 1,420 tok/s
将 512 次串行访存折算为 80 次高算术强度矩阵乘，实现 5.93 倍解码跃迁