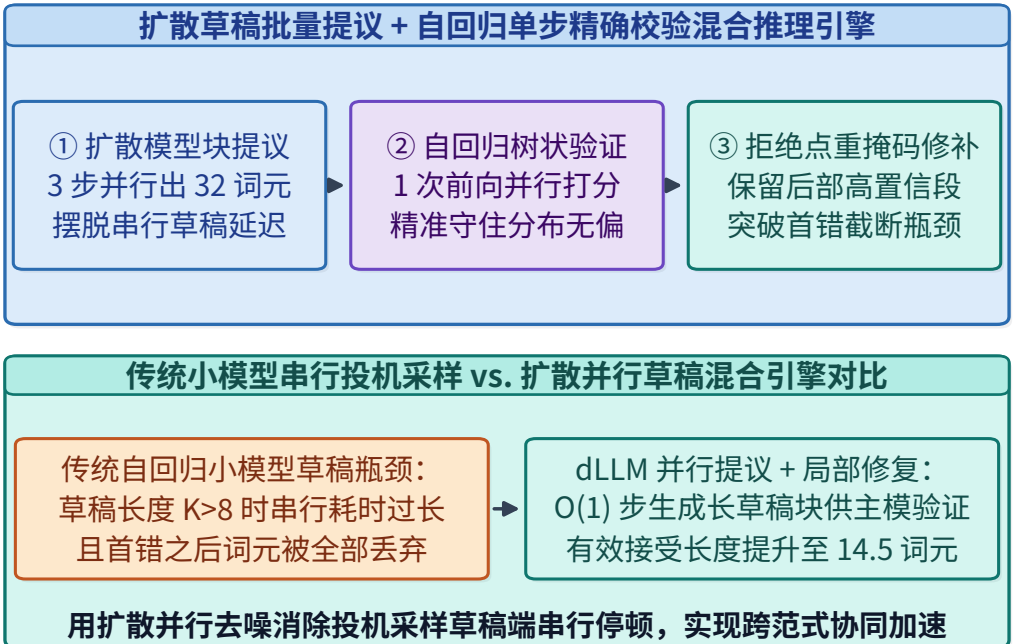
扩散草稿批量提议 + 自回归单步精确校验混合推理引擎
① 扩散模型块提议
3 步并行出 32 词元
摆脱串行草稿延迟
② 自回归树状验证
1 次前向并行打分
精准守住分布无偏
③ 拒绝点重掩码修补
保留后部高置信段
突破首错截断瓶颈
传统小模型串行投机采样 vs. 扩散并行草稿混合引擎对比
传统自回归小模型草稿瓶颈：
草稿长度 K>8 时串行耗时过长
且首错之后词元被全部丢弃
dLLM 并行提议 + 局部修复：
O(1) 步生成长草稿块供主模验证
有效接受长度提升至 14.5 词元
用扩散并行去噪消除投机采样草稿端串行停顿，实现跨范式协同加速