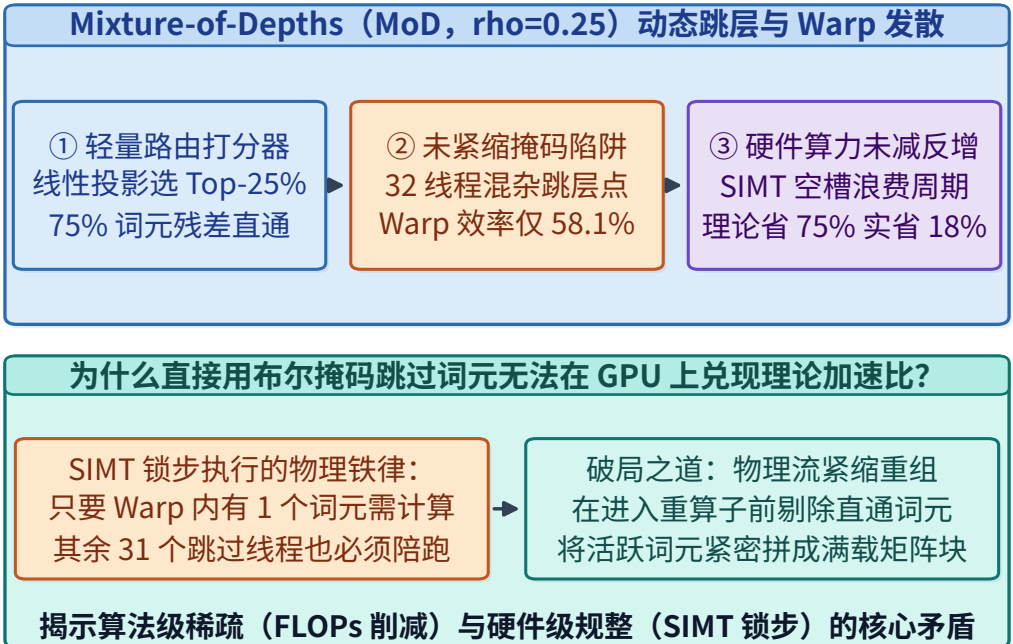
Mixture-of-Depths（MoD，rho=0.25）动态跳层与 Warp 发散
① 轻量路由打分器
线性投影选 Top-25%
75% 词元残差直通
② 未紧缩掩码陷阱
32 线程混杂跳层点
Warp 效率仅 58.1%
③ 硬件算力未减反增
SIMT 空槽浪费周期
理论省 75% 实省 18%
为什么直接用布尔掩码跳过词元无法在 GPU 上兑现理论加速比?
SIMT 锁步执行的物理铁律：
只要 Warp 内有 1 个词元需计算
其余 31 个跳过线程也必须陪跑
破局之道：物理流紧缩重组
在进入重算子前剔除直通词元
将活跃词元紧密拼成满载矩阵块
揭示算法级稀疏（FLOPs 削减）与硬件级规整（SIMT 锁步）的核心矛盾