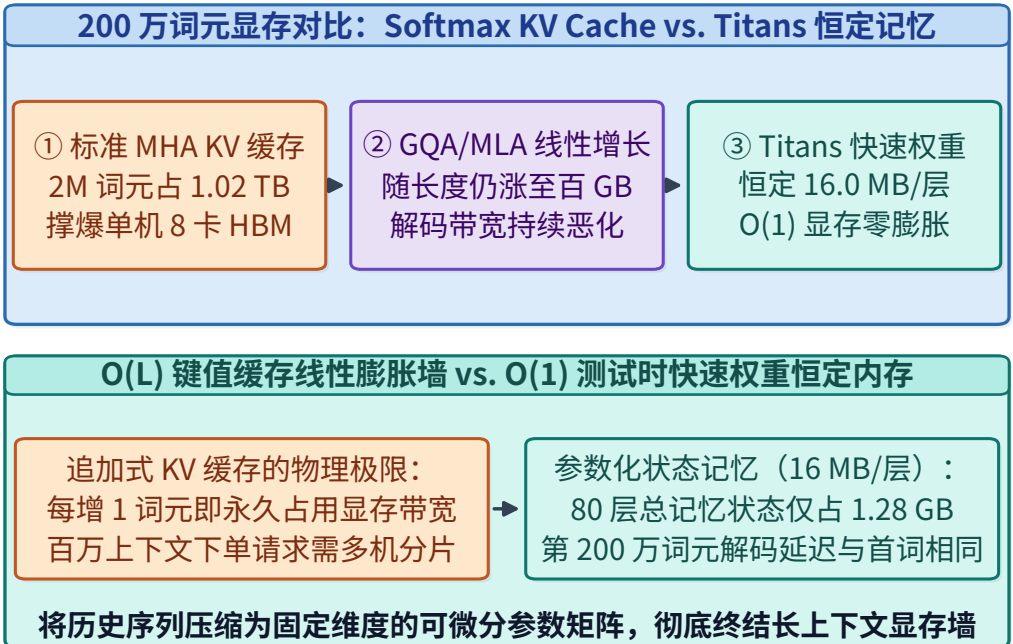
200 万词元显存对比：Softmax KV Cache vs. Titans 恒定记忆
① 标准 MHA KV 缓存
2M 词元占 1.02 TB
撑爆单机 8 卡 HBM
② GQA/MLA 线性增长
随长度仍涨至百 GB
解码带宽持续恶化
③ Titans 快速权重
恒定 16.0 MB/层
O(1) 显存零膨胀
O(L) 键值缓存线性膨胀墙 vs. O(1) 测试时快速权重恒定内存
追加式 KV 缓存的物理极限：
每增 1 词元即永久占用显存带宽
百万上下文下单请求需多机分片
参数化状态记忆（16 MB/层）：
80 层总记忆状态仅占 1.28 GB
第 200 万词元解码延迟与首词相同
将历史序列压缩为固定维度的可微分参数矩阵，彻底终结长上下文显存墙