Google Titans 双系统架构：短期精确注意力 + 长期神经记忆

① 短期滑动窗口注意
精确捕捉局部语法
窗口 W=4,096 词元

② 神经长期记忆模块
片上快速权重 W_t
惊奇度动量在线更新

③ 持久记忆前缀门控
三支路融合注入残差
支持 200 万上下文

将推理期长上下文记忆定义为“测试时在线梯度下降（TTT）”

传统线性 RNN / SSM 表达瓶颈：
固定衰减线性状态容量受限
超长文本大海捞针召回率退化

惊奇度驱动多层感知机记忆：
高梯度反常事实获得强动量写入
权重衰减门自适应腾出记忆容量

梯度即惊奇度，把百万词元历史动态压入恒定体积的片上神经连接权重