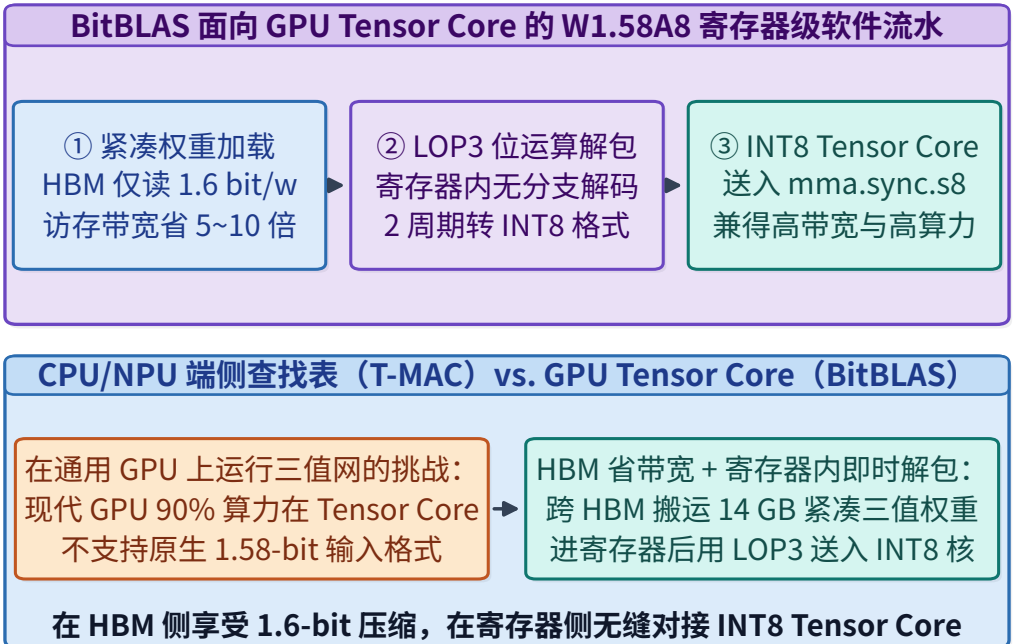
BitBLAS 面向 GPU Tensor Core 的 W1.58A8 寄存器级软件流水
① 紧凑权重加载
HBM 仅读 1.6 bit/w
访存带宽省 5~10 倍
② LOP3 位运算解包
寄存器内无分支解码
2 周期转 INT8 格式
③ INT8 Tensor Core
送入 mma.sync.s8
兼得高带宽与高算力
CPU/NPU 端侧查找表（T-MAC）vs. GPU Tensor Core（BitBLAS）
在通用 GPU 上运行三值网的挑战：
现代 GPU 90% 算力在 Tensor Core
不支持原生 1.58-bit 输入格式
HBM 省带宽 + 寄存器内即时解包：
跨 HBM 搬运 14 GB 紧凑三值权重
进寄存器后用 LOP3 送入 INT8 核
在 HBM 侧享受 1.6-bit 压缩，在寄存器侧无缝对接 INT8 Tensor Core