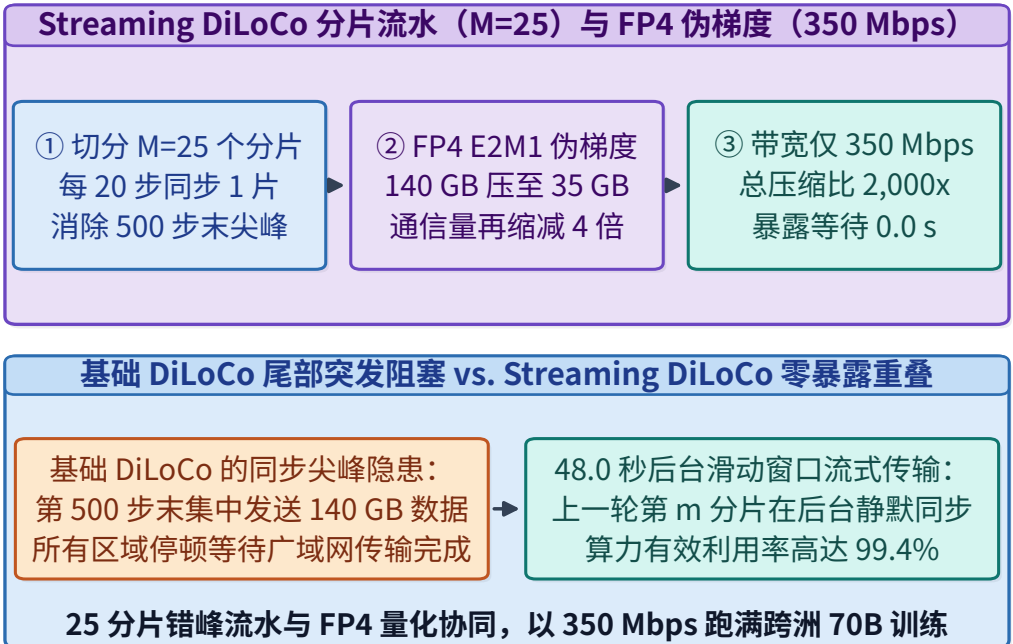
Streaming DiLoCo 分片流水（M=25）与 FP4 伪梯度（350 Mbps）
① 切分 M=25 个分片
每 20 步同步 1 片
消除 500 步末尖峰
② FP4 E2M1 伪梯度
140 GB 压至 35 GB
通信量再缩减 4 倍
③ 带宽仅 350 Mbps
总压缩比 2,000x
暴露等待 0.0 s
基础 DiLoCo 尾部突发阻塞 vs. Streaming DiLoCo 零暴露重叠
基础 DiLoCo 的同步尖峰隐患：
第 500 步末集中发送 140 GB 数据
所有区域停顿等待广域网传输完成
48.0 秒后台滑动窗口流式传输：
上一轮第 m 分片在后台静默同步
算力有效利用率高达 99.4%
25 分片错峰流水与 FP4 量化协同，以 350 Mbps 跑满跨洲 70B 训练