DeepEP Low-Latency 模式：纯 IBGDA 零 SM 占用（163 us 派发）

① IBGDA 门铃直写
绕过 CPU 驱动线程
128 专家 163us 派发

② 后台 Hook 轮询
0 个通信 SM 占用
Combine 耗时 194us

③ 全部 132 SM 算
共享专家与通信重叠
微批解码零停顿

为什么在线解码阶段不能分出 24 个 SM 专门跑通信内核?

解码阶段 SM 被抢占的代价：
切走 24 个 SM 使矩阵算力降 18%
且频繁启动小内核引入微秒级抖动

发完门铃即返还 GPU 控制权：
RDMA 网卡硬件在后台搬运词元
由后续算子尾声 Hook 校验完成位

借力 IBGDA 网卡直通与 Hook 轮询，实现零 SM 占用的 163 us 极速派发