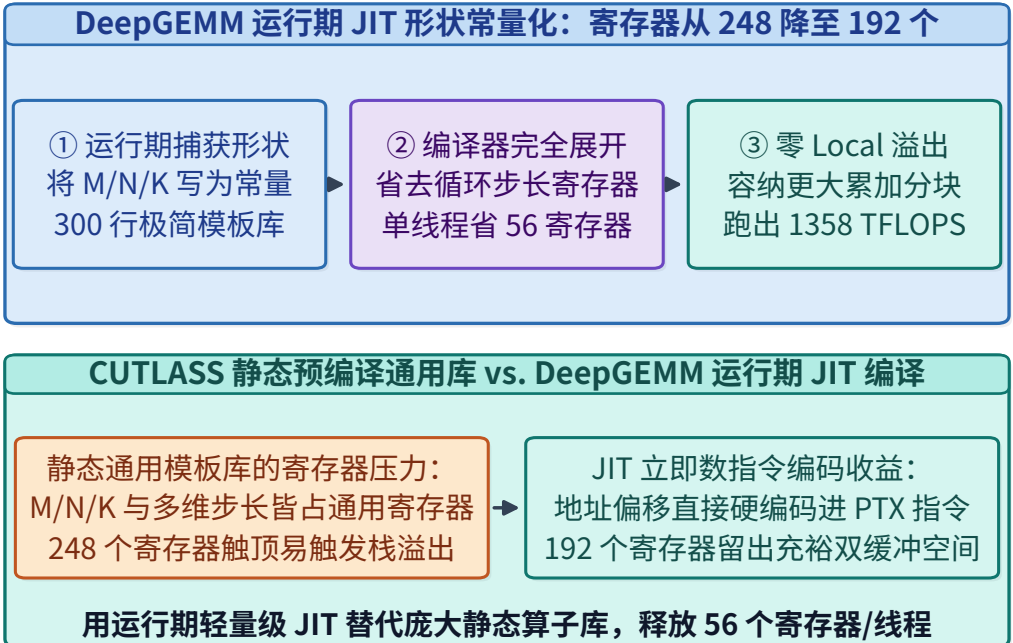
DeepGEMM 运行期 JIT 形状常量化：寄存器从 248 降至 192 个
① 运行期捕获形状
将 M/N/K 写为常量
300 行极简模板库
② 编译器完全展开
省去循环步长寄存器
单线程省 56 寄存器
③ 零 Local 溢出
容纳更大累加分块
跑出 1358 TFLOPS
CUTLASS 静态预编译通用库 vs. DeepGEMM 运行期 JIT 编译
静态通用模板库的寄存器压力：
M/N/K 与多维步长皆占通用寄存器
248 个寄存器触顶易触发栈溢出
JIT 立即数指令编码收益：
地址偏移直接硬编码进 PTX 指令
192 个寄存器留出充裕双缓冲空间
用运行期轻量级 JIT 替代庞大静态算子库，释放 56 个寄存器/线程