第 29 章全景：DeepSeek 算子内核、通信流水与存储底座（上）

29.1 FlashMLA 与 DeepGEMM：
H800 跑出 3,000 GB/s 与 580 TF
JIT 省 56 寄存器达 1,358 TFLOPS

→

29.2 DeepEP 与 DualPipe：
Normal 153 GB/s / IBGDA 163 us
双向流水微批交错实现零通信暴露

第 29 章全景：去缓存文件系统、P-D 分离集群与异构平民部署（下）

29.3 3FS 与 Smallpond：
180 节点聚合随机读 6.60 TB/s
110.5 TiB 排序仅耗时 30 min 14 s

→

29.4 Mooncake 与异构推理：
RDMA KV 池提 2.1x 有效吞吐
单卡+双路 AMX 跑出 18.6 tok/s

贯通七大开源基础设施引擎，树立软硬协同极致效率的现代 AI 系统标杆