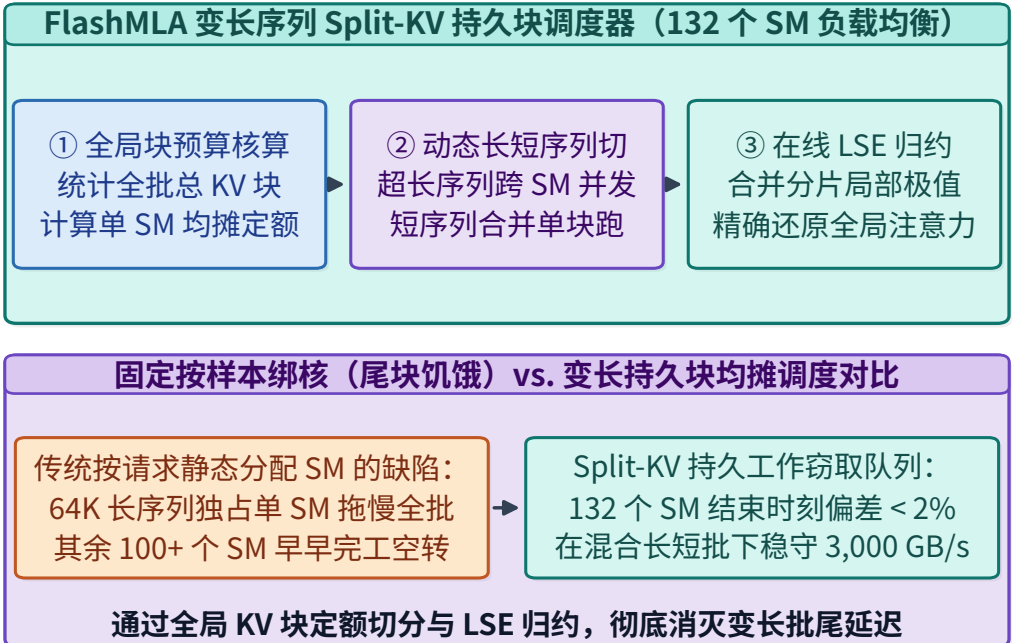
FlashMLA 变长序列 Split-KV 持久块调度器（132 个 SM 负载均衡）
① 全局块预算核算
统计全批总 KV 块
计算单 SM 均摊定额
② 动态长短序列切
超长序列跨 SM 并发
短序列合并单块跑
③ 在线 LSE 归约
合并分片局部极值
精确还原全局注意力
固定按样本绑核（尾块饥饿）vs. 变长持久块均摊调度对比
传统按请求静态分配 SM 的缺陷：
64K 长序列独占单 SM 拖慢全批
其余 100+ 个 SM 早早完工空转
Split-KV 持久工作窃取队列：
132 个 SM 结束时刻偏差 < 2%
在混合长短批下稳守 3,000 GB/s
通过全局 KV 块定额切分与 LSE 归约，彻底消灭变长批尾延迟