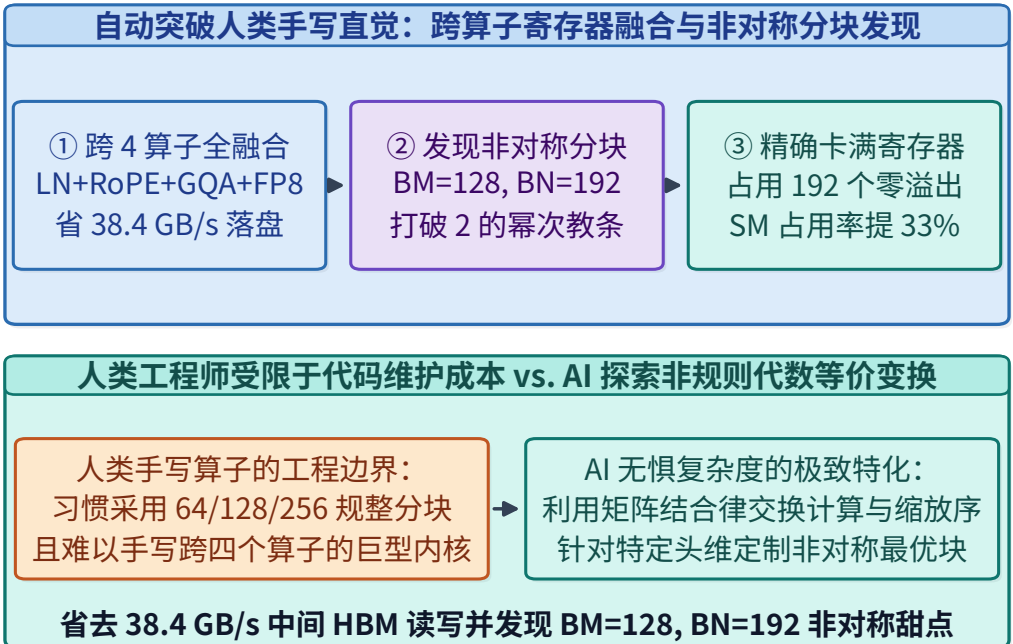
自动突破人类手写直觉：跨算子寄存器融合与非对称分块发现
① 跨 4 算子全融合
LN+RoPE+GQA+FP8
省 38.4 GB/s 落盘
② 发现非对称分块
BM=128, BN=192
打破 2 的幂次教条
③ 精确卡满寄存器
占用 192 个零溢出
SM 占用率提 33%
人类工程师受限于代码维护成本 vs. AI 探索非规则代数等价变换
人类手写算子的工程边界：
习惯采用 64/128/256 规整分块
且难以手写跨四个算子的巨型内核
AI 无惧复杂度的极致特化：
利用矩阵结合律交换计算与缩放序
针对特定头维定制非对称最优块
省去 38.4 GB/s 中间 HBM 读写并发现 BM=128, BN=192 非对称甜点