十万卡自治运维（Autonomous AIOps）：慢节点与 PFC 根因诊断图

① 多源遥测流汇聚
NCCL 环路延迟偏度
光模块 SNR 与温度

② 时空因果图推理
区分真慢卡与受害者
锁定故障交换机口

③ 亚分钟自动处置
42 秒隔离并热替换
零人工介入自愈

为什么 Ring AllReduce 中 1 张慢卡会让全环 32,768 张卡同时报警?

集合通信故障传染与定位迷雾：
单光模块误码或单口 PFC 风暴
会导致整条通信环路全员超时阻塞

图差分偏度定位算法：
比对通信域延迟张量的非对称拐点
秒级揪出唯一物理始作俑者节点

融合 NCCL 飞行记录仪与光模块遥测，在 32,768 卡中秒级锁定罪魁祸首