第一至第三部类（第 1–12 章）核心知识图谱与定量性能锚点

第 1–4 章：单机算力
GPU/TPU微架构定律
Roofline与CXL内存池

第 5–8 章：通信与训练
NVL72/576 与 RoCEv2
5D 并行、FP8 与容错

第 9–12 章：推理与云
分页注意力与P-D分离
K8s 调度、观测与端侧

支撑现代万亿参数大模型的三大基础底座（算力、互连、训练与服务）

向上承托全场景模型演进：
将单卡微架构极限转化为万卡扩展
消除显存墙、通信墙与长尾延迟墙

向下扎根第一性原理核算：
每章均配备零依赖可运行实验套件
从字节与时钟周期推导系统最优解

夯实“硬件微架构—超节点互连—分布式训练—高吞吐推理”十二章主干底座